



МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)

ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ
по дисциплине «Технологии и инструментарий анализа больших данных»

Практическая работа №8

Студент группы *ИКБО-06-22, Ляхов Т.А.*

(подпись)

Проверил *Старший преподаватель,
Приходько Н.А.*

(подпись)

Отчет представлен «__» _____ 2025 г.

Москва 2025 г.


ЗАДАНИЕ

1. Настроить виртуальную машину Ubuntu Server 22.04.5 LTS в системе виртуализации операционных систем, а также настроить Docker контейнеры PostgreSQL, Arundata Cluster Manager совместно с бандлами для кластера и мониторинга
2. Создать базу данных ecommerce и развернуть public схему таблиц, на основе приложенного скрипта
3. Написать запросы на языке SQL для базы данных ecommerce
4. Построить дашборд в Grafana для визуализации данных из ecommerce

РЕЗУЛЬТАТЫ РАБОТЫ

Была создана виртуальная машина на базе Ubuntu Server 22.04.5 LTS в системе виртуализации VirtualBox с параметрами: 2 ГБ ОЗУ, 1 ядро CPU, 25 ГБ HDD, тип подключения: Bridged Adapter (сетевой мост).

На ВМ установлены и запущены Docker-контейнеры: postgres:13 (внутренняя БД для ADCM) и arenadata/adcm:2.7.1. Запущенные контейнеры показаны на рисунке 1.



CONTAINER ID	IMAGE	COMMAND	CREATED	STATUS	PORTS	NAMES
8f70795e9ae3	arenadata/adcm:2.7.1	"/etc/startup.sh"	5 hours ago	Up About an hour	0.0.0.0:8000->8000/tcp, [::]:8000->8000/tcp	adcm
9c15af1c9b61	postgres:13	"docker-entrypoint.s..."	5 hours ago	Up About an hour	5432/tcp	adcm-db

Рисунок 1 – Запущенные контейнеры

Через веб-интерфейс ADCM были загружены: adcm_host_ssh_v2.11-1_community.tar, adcm_cluster_adpg_v16.3_arenadata4.4_b1-1_community.tar.

Создан кластер adpg_cluster, на который установлены сервисы ADPG и Monitoring (рисунок 2).




Рисунок 2 – Кластер adpg_cluster

В PostgreSQL создана база данных ecommerce. Выполнен импорт данных из CSV-файлов.

Схема базы данных показана на рисунке 3.




Рисунок 3 – Схема базы данных

Для выполнения задания 3.1 был составлен SQL-запрос, объединяющий таблицы `order_items`, `products` и `product_category_name_translation`. С его помощью рассчитаны ключевые бизнес-метрики по каждой товарной категории: выручка (сумма цен всех проданных позиций), количество уникальных заказов, в которых встречались товары этой категории, общее число проданных позиций.

Кроме того, к исходному названию категории добавлен её официальный перевод на английский язык из справочной таблицы `product_category_name_translation`.

Результат отсортирован по убыванию выручки и ограничен 10 записями, как того требует задание.

Листинг 1 – Запрос 3.1

```

SELECT
    p.product_category_name AS original_category,
    pnt.product_category_name_english AS category,
    SUM(oi.price) AS revenue,
    COUNT(DISTINCT o.order_id) AS unique_orders,
    COUNT(oi.order_item_id) AS total_items
FROM order_items oi

```

```

JOIN products p ON oi.product_id = p.product_id
JOIN product_category_name_translation pnt
  ON p.product_category_name = pnt.product_category_name
JOIN orders o ON oi.order_id = o.order_id
GROUP BY p.product_category_name, pnt.product_category_name_english
ORDER BY revenue DESC
LIMIT 10;

```

	A-Z original_category	A-Z category	123 revenue	123 unique_orders	123 total_items
1	beleza_saude	health_beauty	1 258 681,34	8 836	9 670
2	relogios_presentes	watches_gifts	1 205 005,68	5 624	5 991
3	cama_mesa_banho	bed_bath_table	1 036 988,68	9 417	11 115
4	esporte_lazer	sports_leisure	988 048,97	7 720	8 641
5	informatica_acessorios	computers_accessories	911 954,32	6 689	7 827
6	moveis_decoracao	furniture_decor	729 762,49	6 449	8 334
7	cool_stuff	cool_stuff	635 290,85	3 632	3 796
8	utilidades_domesticas	housewares	632 248,66	5 884	6 964
9	automotivo	auto	592 720,11	3 897	4 235
10	ferramentas_jardim	garden_tools	485 256,46	3 518	4 347

Рисунок 4 – Задание 3.1

Для анализа способов оплаты был составлен SQL-запрос, который:

- группирует платежи по типу (payment_type);
- рассчитывает общее количество платежей (payment_count);
- вычисляет среднее число рассрочек (avg_installments);
- определяет средний размер платежа (avg_payment_value);
- рассчитывает долю заказов, в которых используется данный

способ оплаты (order_share), как отношение количества уникальных заказов с этим типом платежа к общему числу заказов с оплатой.

Запрос корректно учитывает, что у одного заказа может быть несколько платежей: доля рассчитывается на уровне «есть/нет» по заказу.

Листинг 2 – Запрос 3.2

```

WITH total_orders AS (
  SELECT COUNT(DISTINCT order_id) AS total_cnt
  FROM order_payments
)
SELECT
  op.payment_type,
  COUNT(*) AS payment_count,
  AVG(op.payment_installments) AS avg_installments,
  AVG(op.payment_value) AS avg_payment_value,
  COUNT(DISTINCT op.order_id)::NUMERIC / (SELECT total_cnt FROM total_orders) AS order_share
FROM order_payments op
GROUP BY op.payment_type
ORDER BY order_share DESC;

```

	AZ payment_type	123 payment_count	123 avg_installments	123 avg_payment_value	123 order_share
1	credit_card	76 795	3,5071554138	163,3190206394	0,7693584071
2	boleto	19 784	1	145,0344354023	0,1989541432
3	voucher	5 775	1	65,7033541126	0,0388777152
4	debit_card	1 529	1	142,5701700458	0,0153660499
5	not_defined	3	1	0	0,0000301689

Рисунок 5 – Задание 3.2

Для анализа влияния скорости доставки на удовлетворённость клиентов был составлен SQL-запрос, объединяющий таблицы orders и order_reviews. Для каждого заказа с известными датами покупки и доставки рассчитана длительность доставки в днях. Заказы распределены по трём интервалам: «<=5 days», «6–10 days» и «>10 days». Для каждого интервала подсчитано количество заказов и средняя оценка из отзывов. Результат отсортирован в логическом порядке от самого быстрого к самому длительному интервалу.

Листинг 3 – Запрос 3.3

```

SELECT
CASE
    WHEN delivery_days <= 5 THEN '<=5 days'
    WHEN delivery_days BETWEEN 6 AND 10 THEN '6–10 days'
    ELSE '>10 days'
END AS delivery_interval,
COUNT(*) AS order_count,
AVG(review_score) AS avg_score
FROM (
    SELECT
        o.order_id,
        orv.review_score,
        (o.order_delivered_customer_date::DATE - o.order_purchase_timestamp::DATE) AS delivery_days
    FROM orders o
    JOIN order_reviews orv ON o.order_id = orv.order_id
    WHERE o.order_delivered_customer_date IS NOT NULL
    AND o.order_purchase_timestamp IS NOT NULL
) AS sub
GROUP BY
CASE
    WHEN delivery_days <= 5 THEN '<=5 days'
    WHEN delivery_days BETWEEN 6 AND 10 THEN '6–10 days'
    ELSE '>10 days'
END
ORDER BY
CASE
    WHEN MAX(delivery_days) <= 5 THEN 1
    WHEN MAX(delivery_days) BETWEEN 6 AND 10 THEN 2
    ELSE 3
END;

```

	AZ delivery_interval	123 order_count	123 avg_score
1	<= 5 days	16 518	4,442789684
2	6-10 days	32 710	4,3547844696
3	> 10 days	45 639	3,9174609435

Рисунок 6 – Задание 3.3

Для оценки эффективности продавцов был написан SQL-запрос, объединяющий таблицы order_items и orders. Для каждого продавца рассчитаны следующие метрики:

- количество уникальных заказов,
- число уникальных клиентов,
- общее количество проданных позиций,
- совокупный оборот (сумма цен всех позиций),
- средняя стоимость доставки на позицию (freight_value).

Результат отсортирован по убыванию числа заказов, и выбраны 10 лучших продавцов (ТОП-10).

Листинг 4 – Запрос 3.4

```
SELECT
  oi.seller_id,
  COUNT(DISTINCT oi.order_id) AS unique_orders,
  COUNT(DISTINCT o.customer_id) AS unique_customers,
  COUNT(oi.order_item_id) AS total_items,
  SUM(oi.price) AS total_revenue,
  AVG(oi.freight_value) AS avg_freight_per_item
FROM order_items oi
JOIN orders o ON oi.order_id = o.order_id
GROUP BY oi.seller_id
ORDER BY unique_orders DESC
LIMIT 10;
```

	AZ seller_id	123 unique_orders	123 unique_customers	123 total_items	123 total_revenue	123 avg_freight_per_item
1	6560211a19b47992c3666cc44a7e94c0	1 854	1 854	2 033	123 304,83	13,7535366454
2	4a3ca9315b744ce9f8e9374361493884	1 806	1 806	1 987	200 472,92	17,6482335179
3	cc419e0650a3c5ba77189a1882b7556a	1 706	1 706	1 775	104 288,42	14,4614028169
4	1f50f920176fa81dab994f9023523100	1 404	1 404	1 931	106 939,21	18,211170378
5	da8622b14eb17ae2831f4ac5b9dab84a	1 314	1 314	1 551	160 236,57	16,0901031593
6	955fee9216a65b617aa5c0531780ce60	1 287	1 287	1 499	135 171,7	16,9652968646
7	7a67c85e85bb2ce8582c35f2203ad736	1 160	1 160	1 171	141 745,53	17,8504269855
8	ea8482cd71df3c1969d7b9473ff13abc	1 146	1 146	1 203	37 177,52	14,5841812136
9	4869f7a5dfa277a7dca6462dcf3b52b2	1 132	1 132	1 156	229 472,63	17,4464273356
10	3d871de0142ce09b7081e2b9d1733cb1	1 080	1 080	1 147	94 914,2	19,5584219704

Рисунок 7 – Задание 3.4

Динамика числа заказов

Для анализа сезонности и тренда продаж был построен линейный график (time series) в Grafana, отображающий количество уникальных заказов по месяцам. Данные получены путём агрегации таблицы orders по полю order_purchase_timestamp.




Рисунок 8 – Визуализация 4.1

На представленном линейном графике отображена динамика общего количества уникальных заказов по месяцам с ноября 2017 года по сентябрь 2018 года.

График демонстрирует четкую восходящую тенденцию в течение большей части периода, что свидетельствует о росте активности пользователей и увеличении объема продаж. Наблюдается выраженная сезонность: наиболее значительный рост приходится на период октябрь–ноябрь 2017 года, а пик — на ноябрь 2017 года (более 7500 заказов). Это, вероятно, связано с предпраздничным спросом (Black Friday, Рождество).

После ноября 2017 года наблюдается небольшое снижение, однако с начала 2018 года количество заказов снова начинает расти, достигая нового пика в марте 2018 года.

Количество заказов по оценкам

Для выполнения задания 4.2 «Количество заказов по оценкам» была создана линейная визуализация (линейный график), отображающая динамику количества заказов по месяцам.



Рисунок 9 – Визуализация 4.2

На представленном линейном графике отображена динамика общего числа уникальных заказов по месяцам с ноября 2016 года по сентябрь 2018 года.

График демонстрирует устойчивый рост активности пользователей в течение большей части периода. После ноября 2017 года наблюдается небольшое снижение, однако с начала 2018 года количество заказов снова начинает расти, достигая пика в марте 2018 года. Однако в конце периода, в сентябре 2018 года, происходит резкое падение до нуля

Распределение способов оплаты

Для понимания платёжных предпочтений клиентов создана круговая диаграмма (pie chart), отображающая долю каждого способа оплаты среди всех заказов.




Рисунок 10 – Визуализация 4.3

На представленной круговой диаграмме отображено распределение заказов по способам оплаты.

Самым популярным способом является кредитная карта (credit_card), на которую приходится 75% всех заказов. Это свидетельствует о высокой

степени доверия пользователей к онлайн-платежам и их предпочтении в условиях современной электронной коммерции.

Второе место занимает boleto — традиционный для Бразилии способ оплаты, который используется в 19% заказов. Этот метод остается актуальным для сегмента пользователей, предпочитающих оплату через банковские реквизиты без привязки карты.

Остальные способы — voucher, debit_card и not_defined — используются крайне редко и в совокупности составляют менее 6% всех заказов.

ТОП-10 категорий по объёму продаж

Для выявления ключевых категорий товаров построена горизонтальная столбчатая диаграмма, отображающая выручку по товарам. Данные получены из таблиц order_items, products и product_category_name_translation.




Рисунок 11 – Визуализация 4.4

На представленной горизонтальной столбчатой диаграмме отображены ТОП-10 товарных категорий по общему объёму продаж (выручке).

Лидером является категория «health_beauty» (товары для здоровья и красоты), за ней следуют «watches_gifts» (часы и подарки) и «bed_bath_table» (постельное бельё, полотенца, предметы для ванной).

Динамика среднего чека

Для анализа динамики среднего чека была создана линейная визуализация в Grafana, отображающая среднюю стоимость заказа по месяцам. Для этого был использован SQL-запрос, который:

рассчитывает общую выручку (SUM(oj.price)) и количество уникальных заказов (COUNT(DISTINCT o.order_id)) для каждого месяца,

делит первое на второе, чтобы получить средний чек,

группирует результаты по месяцам и сортирует их хронологически.

Это позволило проследить, как менялся средний чек во времени — растёт он, падает или остаётся стабильным.



Рисунок 12 – Визуализация 4.5.1

На представленном графике видно, что средний чек колеблется в районе 120–160 единиц, без устойчивого роста или падения. Наблюдается небольшая волатильность: в сентябре 2016 года средний чек достигал пика в ~160 единиц, а в декабре 2016 года — резко падал до 10 единиц

Доля заказов с несколькими товарами

Для анализа структуры заказов была создана круговая диаграмма (Pie chart) в Grafana. Для этого был использован SQL-запрос, который:

рассчитывает количество позиций (item_count) в каждом заказе,

группирует заказы по трём категориям: «1 item», «2–5 items», «6+ items»,

подсчитывает количество заказов в каждой категории.

Это позволило определить, какая доля заказов содержит один товар, а какая — несколько.




Рисунок 13 – Визуализация 4.5.2

На представленной круговой диаграмме видно, что подавляющее большинство заказов (90%) содержат только 1 товар. Это указывает на то, что

клиенты чаще всего покупают отдельные позиции, а не собирают корзины из нескольких товаров.

Категория «2–5 items» составляет 10% всех заказов, что говорит о небольшом сегменте пользователей, которые делают «комплексные» покупки.

Заказы с 6 и более товарами практически отсутствуют — их доля не показана на графике (менее 1%).

ВЫВОД

В ходе выполнения практической работы №8 была успешно развёрнута инфраструктура на базе Ubuntu Server, Docker, Arenadata Cluster Manager (ADCM) и ADPG, включающая PostgreSQL, Prometheus и Grafana. Создана и наполнена база данных ecommerce, реализованы SQL-запросы для бизнес-аналитики и построен комплексный дашборд в Grafana.